

2209/A

ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEK PROGRAMI

SONUÇ RAPORU

**PROJE BAŞLIĞI: Uydu Görüntülerinden Görüntü İşleme Yöntemleri
ile Oraj Tespiti**

PROJE YÜRÜTÜCÜSÜNÜN ADI: Akif KARACA

DANIŞMANININ ADI: Dr. Öğr. Üyesi Gülşah KARADUMAN

GENEL BİLGİLER

PROJENİN KONUSU	Meteoroloji uydularından elde edilen termal kızılötesi görüntüler üzerinde derin öğrenme yöntemleri kullanılarak oraj (şiddetli konvektif fırtına) içeren ve içermeyen atmosferik durumların otomatik olarak sınıflandırılması.
PROJE YÜRÜTÜCÜSÜNÜN ADI	Akif KARACA
DANIŞMANIN ADI	Dr. Öğr. Üyesi Gülşah KARADUMAN
PROJE BAŞLANGIÇ VE BİTİŞ TARİHLERİ	Mayıs 2025 – Temmuz 2026

İÇİNDEKİLER

1. Giriş	3
1.1. Havacılık güvenliği ve şiddetli meteorolojik olaylar	3
1.2. Uydu tabanlı gözlem ve mevcut yöntemlerin sınırlılıkları.....	3
1.3. Derin öğrenme tabanlı görüntü sınıflandırma	4
1.4. Projenin amacı ve kapsamı.....	5
2. Rapor dönemlerinde yapılan çalışmalar.....	6
2.1. Literatür araştırması ve veri kaynağının belirlenmesi	6
2.2. Veri setinin hazırlanması ve ön işleme çalışmaları	7
2.3. Mevsimsel yansılığın giderilmesi ve olay bazlı doğrulama düzeni	8
2.4. Derin öğrenme modellerinin geliştirilmesi	10
2.5. Eğitim stratejisi ve hiperparametre optimizasyonu.....	10
2.6. Optik akış ile bulut hareketlerinin analizi	12
2.7. Performans değerlendirme protokolü	13
3. Sonuç	15
3.1. Sınıflandırma sonuçları	15
3.2. Karar eşiği optimizasyonu ve model seçimi	18
3.3. Etiket kalitesinin bağımsız değerlendirilmesi	19
3.4. Proje hedeflerinin gerçekleşme düzeyi	20
3.5. Genel değerlendirme, sınırlılıklar ve gelecek çalışmalar	21
4. Çıktılar (Yayınlar, sunumlar v.b.).....	24
5. Proje ile ilgili harcama kalemleri hakkında ayrıntılı bilgi	27
6. Kaynakça	28

1. Giriş

1.1. Havacılık güvenliği ve şiddetli meteorolojik olaylar

Meteorolojik olaylar, havacılık faaliyetlerinin başlangıcından bu yana uçuş güvenliğini doğrudan etkileyen temel etkenler arasında yer almıştır. Kalkış, tırmanma, seyir ve iniş aşamalarının tamamı atmosferik koşullardan etkilenmekte; ani gelişen ve yerel ölçekte şiddetlenen hava olayları, uçuş planlarının değiştirilmesini, rota sapmalarını veya operasyonların askıya alınmasını gerektirebilmektedir. Şiddetli meteorolojik olayların önceden öngörülebilmesi ya da gereken önlemlerin zamanında alınamaması durumunda, uçuş operasyonlarında ciddi sonuçlar doğurabilecek kaza ve kırımlar meydana gelebilmektedir [1].

Havacılık tarihinde troposferde seyreden uçaklar, kümülonimbüs (Cb) bulutları ve bu bulutlarla ilişkili olarak ortaya çıkan oraj, mikroburst, downburst, türbülans, rüzgâr kayması, buzlanma, dolu ve sağanak yağmur gibi şiddetli hava olaylarıyla defalarca karşılaşmış ve bu karşılaşmaların bir kısmı trajik kazalarla sonuçlanmıştır [2]. Amerika Birleşik Devletleri'nde 1964–1981 yılları arasında gerçekleştirilen bir çalışmada, meteorolojik olaylarla bağlantılı uçak kazalarının %43'ünün şiddetli hava koşullarıyla, %6'sının ise doğrudan orajlarla ilişkili olduğu belirlenmiştir [3]. Benzer biçimde Pearson'ın 1995–2000 yıllarını kapsayan araştırması, hava koşullarından kaynaklanan kazaların %63'ünün düşük bulut tabanı ve sınırlı görüş mesafesi, %18'inin rüzgâr ve türbülans, %5'inin ise gök gürültülü fırtınalarla ilişkili olduğunu ortaya koymuştur [4].

Orajlar ve kümülonimbüs bulutları, atmosferdeki yoğun kararsızlık sonucu oluşan ve güçlü dikey gelişim gösteren bulut yapılarıdır. İçerdikleri yoğun su buharı ve buz kristalleri nedeniyle çok yüksek seviyelere, kimi durumlarda troposferi aşarak stratosfere kadar uzanabilmektedirler. Bu bulutlar yoğun sağanak yağış, dolu, yıldırım, kuvvetli rüzgâr ve türbülans gibi çok sayıda tehlikeyi bir arada barındırır. Bu nedenle gök gürültülü fırtınalarla karakterize edilen orajlar, özellikle uçuş sırasında oluşan türbülanslar nedeniyle hava taşımacılığı için yüksek risk teşkil etmektedir [5].

Türkiye özelinde yapılan çalışmalarda da orajların ve kümülonimbüs bulutlarının uçuş güvenliği üzerindeki etkileri incelenmiştir. Atatürk Havalimanı'nda 2008–2012 dönemini kapsayan METAR ve SPECI verilerinin analizi, İstanbul'un bu tür meteorolojik olaylara ne derece açık olduğunu ortaya koymaktadır. Söz konusu çalışmaya göre en fazla Cb bulutu 2009 yılının Eylül ayında, en fazla oraj ise 2010 yılının Haziran ayında gözlenmiştir [6]. Bu bulgular, yoğun hava trafiğine sahip havalimanlarında şiddetli meteorolojik olayların önceden tespit edilmesinin uçuş güvenliği açısından taşıdığı önemi göstermektedir.

1.2. Uydu tabanlı gözlem ve mevcut yöntemlerin sınırlılıkları

Hava olaylarının öngörülmesinde geleneksel olarak sayısal hava tahmini (Numerical Weather Prediction – NWP) modelleri, hava radarları ve yer tabanlı meteorolojik ölçüm cihazları kullanılmaktadır [7]. Radar tabanlı sistemler, yaklaşık 60 km yarıçapındaki bir alanı tarayarak uçak yönünde gelişen fırtınaların yansımalarını tespit edebilmektedir. Ancak bu yöntemler sınırlı bir alan taraması yapabildikleri için büyük ölçekli atmosferik olayları bütüncül biçimde kapsayamamakta ve kısa vadeli tahminlerde yetersiz kalabilmektedir [8].

Meteoroloji uyduları ise çok daha geniş coğrafyaları düzenli aralıklarla ve kesintisiz olarak gözlemlene imkânı sunmaktadır. Özellikle jeostasyoner uydular, aynı bölgeyi birkaç dakikalık aralıklarla görüntüleyerek konvektif sistemlerin gelişim sürecinin izlenmesine olanak tanımaktadır. Uydu görüntülerinin görünür (VIS) ve termal kızılötesi (IR) kanalları, bulut yapılarının farklı fiziksel özelliklerini yansıtmaktadır.

Bu çalışmada termal kızılötesi kanal esas alınmıştır. Bu tercihin iki temel gerekçesi bulunmaktadır. Birincisi fizikseldir: derin konvektif bulutların tepeleri tropopoz seviyesine kadar yükseldiği için son derece düşük parlaklık sıcaklıklarına sahiptir ve bu durum orajın en ayırt edici uzaktan algılama imzasını oluşturur. İkincisi ise operasyoneldir: termal kanal güneş ışığına bağımlı olmadığından gece koşullarında da kullanılabilir. Görünür kanal ise gece boyunca kullanılamaz durumdadır. Gerçek zamanlı bir erken uyarı sisteminin günün her saatinde çalışması gerektiğinden, termal kanalın kullanılması yöntemin uygulanabilirliği açısından belirleyicidir.

1.3. Derin öğrenme tabanlı görüntü sınıflandırma

Uydu görüntülerinden bulut yapılarının tanınması, klasik görüntü işleme yaklaşımlarında eşik değerleri ve el ile tanımlanmış öznitelikler aracılığıyla gerçekleştirilmiştir. Ancak konvektif sistemlerin biçimleri, boyutları ve gelişim aşamaları büyük değişkenlik gösterdiğinden, sabit kurallara dayalı yöntemler sınırlı kalabilmektedir. Evrişimli sinir ağları (Convolutional Neural Networks – CNN), görüntülerden ayırt edici öznitelikleri doğrudan veriden öğrenebilmeleri nedeniyle bu tür problemlerde yaygın biçimde kullanılmaktadır.

Derin ağların eğitiminde karşılaşılan temel güçlüklerden biri, katman sayısı arttıkça gradyanların zayıflaması ve eğitimin kararsızlaşmasıdır. ResNet mimarisi, katmanlar arasına eklenen artık (residual) bağlantılar sayesinde bilginin daha derin katmanlara kayıpsız aktarılmasını sağlamakta ve çok katmanlı ağların kararlı biçimde eğitilebilmesine imkân tanımaktadır [9]. DenseNet mimarisi ise her katmanın çıktısını kendisinden sonraki tüm katmanlara ileterek katmanlar arası bilgi akışını güçlendirmekte ve daha az parametreyle benzer temsil kapasitesine ulaşabilmektedir [10].

Sınırlı büyüklükteki veri setlerinde bu mimarilerin sıfırdan eğitilmesi genellikle aşırı öğrenmeye yol açmaktadır. Bu nedenle büyük ölçekli genel amaçlı görüntü veri setleri üzerinde önceden eğitilmiş ağırlıkların aktarılması (transfer öğrenme) yaygın bir yaklaşımdır [11]. Aktarılan ağırlıkların hedef veri setine uyarlanması sırasında öğrenme oranının ve hangi katmanların serbest bırakılacağına dikkatli seçilmesi gerekmektedir; aksi hâlde önceden öğrenilmiş temsiller bozulabilmektedir. Bu süreçte toplu normalleştirme (Batch Normalization) katmanlarının davranışı özellikle belirleyicidir [12].

Derin öğrenme uygulamalarında sıkça karşılaşılan iki metodolojik risk, bu çalışmanın tasarımında özellikle dikkate alınmıştır. Bunlardan ilki kısayol öğrenmesidir (shortcut learning): model, problemin gerçek nedensel yapısını öğrenmek yerine veri setinde tesadüfen bulunan ve etiketle ilişkili görünen yardımcı ipuçlarını kullanabilir. Bu durumda ölçülen başarı yüksek görünse de model gerçek dünyada başarısız olur [13]. İkincisi veri sızıntısıdır (data leakage): değerlendirme kümesine, eğitim kümesindeki örneklerle aynı kaynaktan gelen veya onlarla güçlü biçimde ilişkili örneklerin karışması, performansın gerçekte olduğundan yüksek ölçülmesine yol açar [14]. Her iki risk de aşağıda açıklanan deney düzeniyle önlenmiştir.

1.4. Projenin amacı ve kapsamı

Bu çalışmanın temel amacı, meteoroloji uydularından elde edilen termal kızılötesi görüntüler üzerinde derin öğrenme yöntemleri kullanılarak oraj içeren ve içermeyen atmosferik durumların otomatik olarak ayırt edilmesini sağlayan bir sınıflandırma yaklaşımı geliştirmektir. Araştırma önerisinde uydu görüntülerinden görüntü işleme yöntemleriyle oraj tespiti hedeflenmiş; gerçekleştirilen uygulamada bu kapsam, termal kızılötesi kanal üzerinden ikili sınıflandırma problemi olarak özelleştirilmiştir.

Bu amaç doğrultusunda öncelikle etiketli uydu görüntülerinden oluşan bir veri seti oluşturulmuş, görüntüler fiziksel birimlerine dönüştürülerek normalleştirilmiş ve model eğitime uygun hâle getirilmiştir. Ardından ResNet50 ve DenseNet121 mimarileri aynı deney protokolü altında eğitilerek karşılaştırılmıştır. Değerlendirmede yalnızca genel doğruluk değil, sınıf bazlı kesinlik, duyarlılık, F1 skoru ve ROC-AUC ölçütleri birlikte kullanılmış; ayrıca karar eşiği optimizasyonu gerçekleştirilmiştir.

Havacılık güvenliği bağlamında bir orajın gözden kaçırılması ile normal bir durumun yanlışlıkla oraj olarak işaretlenmesi aynı sonuca sahip değildir. Tespit edilemeyen bir konvektif sistem doğrudan uçuş güvenliği riski oluştururken, yanlış alarmin maliyeti yalnızca gereksiz bir uyarı ve ek kontroldür. Bu asimetri, çalışmada karar eşiğinin belirlenmesinde açık bir tasarım ölçütü olarak kullanılmıştır.

Projenin gerçekleştirilen kapsamı; veri setinin hazırlanması, ön işleme, model geliştirme, eğitim, karar eşiği optimizasyonu, optik akış tabanlı hareket analizi, etiket kalitesinin bağımsız doğrulanması ve çevrimdışı performans değerlendirmesi aşamalarını içermektedir. Araştırma önerisinde yer alan YOLO mimarisiyle nesne tespiti ve gerçek zamanlı meteorolojik karar destek sistemlerine entegrasyon ise proje süresi içerisinde gerçekleştirilememiştir. Bu durumun gerekçeleri ilgili bölümlerde ayrıntılı biçimde açıklanmıştır.

2. Rapor dönemlerinde yapılan çalışmalar

Proje süresince uydu görüntülerinden oraj tespitine yönelik bir derin öğrenme sisteminin geliştirilmesi amacıyla literatür araştırması, veri kaynağının belirlenmesi, veri setinin hazırlanması, ön işleme, model geliştirme, eğitim, karar eşiği optimizasyonu ve performans değerlendirme aşamaları yürütülmüştür. Araştırma önerisinde belirlenen temel yaklaşım korunmuş; ancak deney düzeninin bilimsel geçerliliğini sağlamak amacıyla öneride yer almayan bazı metodolojik önlemler de çalışmaya dâhil edilmiştir.

Araştırma önerisinde tanımlanan iş paketlerinin gerçekleşme durumu Tablo 1’de özetlenmiştir.

İP	İş paketi	Gerçekleşme durumu
1	Uydu görüntülerinin toplanması ve ön işleme tabi tutulması	Gerçekleştirildi
2	Optik akış algoritmaları ile bulut hareketlerinin izlenmesi	Kısmen gerçekleştirildi
3	Algoritmaların eğitilmesi ve karşılaştırılması	Kısmen gerçekleştirildi
4	Seçilen modelin eğitilmesi ve hiperparametre optimizasyonu	Gerçekleştirildi
5	Model performansının metriklerle test edilmesi	Gerçekleştirildi
6	Sonuçların yorumlanması ve görselleştirilmesi	Gerçekleştirildi

Tablo 1. Araştırma önerisindeki iş paketlerinin gerçekleşme durumu.

2.1. Literatür araştırması ve veri kaynağının belirlenmesi

Projenin ilk aşamasında havacılık meteorolojisi, kümülonimbüs bulutlarının uçuş güvenliğine etkileri, uydu tabanlı konvektif sistem tespiti, uzaktan algılama verilerinin ön işlenmesi ve derin öğrenme tabanlı görüntü sınıflandırma konularında literatür araştırması yapılmıştır [1]–[8], [15]. İnceleme sonucunda, uydu görüntülerinden şiddetli fırtına tespitinin görsel öğrenme yöntemleriyle ele alınabildiği ve bu alanda etiketli veri kalitesinin başarıyı belirleyen en kritik unsur olduğu görülmüştür.

Araştırma önerisinde veri kaynağı olarak Kaggle ve NASA arşivleri öngörülmüştü. Proje sürecinde yapılan ayrıntılı inceleme sonucunda, bu kaynaklarda erişilebilen uydu görüntü koleksiyonlarının denetimli öğrenme için gerekli olan doğrulanmış olay etiketlerini içermediği belirlenmiştir. Bu koleksiyonlarda görüntüler çoğunlukla ham arşiv biçiminde sunulmakta; hangi görüntünün gerçekten bir şiddetli hava olayına karşılık geldiği bilgisi bulunmamaktadır. Etiketlerin araştırmacı tarafından elle üretilmesi, uzman meteorolojik değerlendirme gerektirdiğinden proje kapsamı dışında kalmıştır.

Bu nedenle veri kaynağı, MIT Lincoln Laboratory tarafından hazırlanan ve AWS Açık Veri Programı üzerinden ücretsiz erişime sunulan SEVIR (Storm EVent ImagRy) veri seti olarak değiştirilmiştir [15]. SEVIR’in tercih edilmesinin başlıca gerekçeleri şunlardır:

- Veri setindeki olaylar NOAA Storm Events veri tabanıyla eşleştirilmiş olduğundan etiketler kurumsal bir kaynağa dayanmaktadır.

- Her olay 384 km × 384 km'lik bir alanı ve dört saatlik bir zaman aralığını kapsayacak biçimde, 5 dakikalık aralıklarla 49 zaman adımı olarak saklanmaktadır. Bu yapı, zamansal analiz yapılmasına da imkân tanımaktadır.
- Görünür kanal, iki farklı kızılötesi kanal, radar türetilmiş sıvı su içeriği ve yıldırım verisi olmak üzere çok kanallı gözlem sunmaktadır. Bu çalışmada yıldırım kanalı, etiket kalitesinin bağımsız olarak doğrulanmasında da kullanılmıştır (Bölüm 3.3).
- Erişimi tamamen açık ve ücretsizdir; bu durum çalışmanın tekrarlanabilirliğini artırmaktadır.

Bu değişiklik projenin bilimsel hedeflerinde bir sapmaya yol açmamış, aksine denetimli öğrenme için gerekli etiket güvenilirliğini sağlayarak çalışmanın metodolojik zeminini güçlendirmiştir.

2.2. Veri setinin hazırlanması ve ön işleme çalışmaları

Çalışmada SEVIR veri setinin 10,7 µm dalga boyundaki termal kızılötesi kanalı (ir107) kullanılmıştır. Bu kanal 4 km uzamsal çözünürlükte olup her olay için 192 × 192 piksel boyutunda görüntüler içermektedir. Sınıf etiketleri, SEVIR arşivinin kendi yapısından türetilmiştir: NOAA Storm Events kayıtlarıyla eşleştirilmiş olaylar (STORMEVENTS) oraj sınıfı (1), rastgele seçilmiş zaman ve konumlardaki olaylar (RANDEVENTS) ise normal sınıf (0) olarak etiketlenmiştir.

Veri hazırlama sürecinde aşağıdaki adımlar uygulanmıştır:


Fiziksel birime dönüştürme: SEVIR verisi disk alanından tasarruf amacıyla tam sayı biçiminde saklanmaktadır. Kızılötesi kanallar için resmî ölçek katsayısı 1/100 olup, ham değerlerin bu katsayıyla çarpılması santigrat cinsinden parlaklık sıcaklığı vermektedir. Proje sürecinde yapılan ilk denemelerde bu dönüşümün atlanması hâlinde piksel değerlerinin neredeyse tamamının normalizasyon sırasında kırıldığı ve termal bilginin ikili bir eşik değerine indirildiği tespit edilmiştir. Bu hatanın giderilmesi, modelin kullanabileceği bilgi miktarını doğrudan artırmıştır. Dönüşüm sonrasında ölçülen ham değer aralıkları, oraj sınıfı için yaklaşık -68,9 °C ile +24,4 °C arasında değişmekte olup fiziksel olarak beklenen sınırlarla uyumludur.

Normalizasyon: Sıcaklık değerleri, +30 °C ile -90 °C aralığı 0–1 aralığına karşılık gelecek biçimde ters yönde ölçeklenmiştir. Bu sayede sıcak yer yüzeyi düşük, soğuk konvektif bulut tepeleri ise yüksek piksel değerleriyle temsil edilmiş; aranan fiziksel olgu görüntüde parlak bölgeler hâline getirilmiştir. Aralık dışındaki değerler kırılmıştır.

Zamansal örnekleme: Her olayın 49 zaman adımından eşit aralıklarla 9 kare seçilmiştir. Böylece fırtınanın gelişim, olgunluk ve dağılma evrelerinin tamamı veri setinde temsil edilmiştir. Kare seçimi rastgele değil deterministik yapıldığından, doğrulama sonuçları tekrar edilebilir niteliktedir.

Veri artırma: Eğitim kümesinde 90° katlarında döndürme ile yatay ve dikey aynalama uygulanmıştır [16]. Meteorolojik görüntülerde bu dönüşümler sınıf bilgisini değiştirmemektedir. Doğrulama kümesinde veri artırma uygulanmamış; performans ölçümünün dönüşüm uygulanmamış görüntüler üzerinden yapılması sağlanmıştır.

Geçerlilik denetimi: Veri seti kurulurken katalog kayıtlarındaki dosya indekslerinin ilgili veri dosyasının gerçek boyutuyla uyumlu olup olmadığı denetlenmiş, uyumsuz kayıtlar veri setine hiç alınmamıştır. Böylece eğitim sırasında okuma hatası oluşması ve hatalı örneklerin sessizce veri setine karışması önlenmiştir.



Şekil 1. Veri setindeki oraj (üst sıra) ve normal (alt sıra) sınıflarına ait örnek termal kızılötesi görüntüler. Parlak bölgeler soğuk bulut tepelerini temsil etmektedir.

2.3. Mevsimsel yanlılığın giderilmesi ve olay bazlı doğrulama düzeni

Deney düzeninin oluşturulmasında, ölçülen performansın gerçek genelleme başarısını yansıtmamasını engelleyebilecek iki risk tespit edilmiş ve giderilmiştir. Bu bölüm, çalışmanın önemli metodolojik katkısını oluşturmaktadır.

Mevsimsel yanlılık. SEVIR arşivinde oraj ve rastgele olay dosyaları farklı zaman aralıklarının kapsamaktadır. Proje kapsamında kullanılan dosyalarda oraj verisi Ocak–Haziran, rastgele veri ise Mayıs–Ağustos dönemini içermektedir. Herhangi bir zaman filtresi uygulanmadan çalışıldığında oraj sınıfı kış aylarını da kapsarken karşıt sınıf yalnızca yaz aylarından oluşmaktadır. Termal kızılötesi görüntülerde kış ve yaz aylarının yer yüzeyi sıcaklıkları arasında çok belirgin bir fark bulunduğundan, model oraj tespiti yerine mevsim ayrımı yaparak yüksek doğruluk elde edebilir. Bu, kısayol öğrenmesinin tipik bir örneğidir [13]. Söz konusu yanlılığı ortadan kaldırmak için her iki sınıf da iki dosyanın ortak zaman aralığı olan 1 Mayıs – 30 Haziran 2018 penceresine kısıtlanmıştır.

Veri sızıntısı. Aynı olaya ait ardışık kareler beş dakikalık aralıklarla kaydedildiğinden birbirleriyle çok yüksek korelasyona sahiptir. Veri bölme işlemi kare düzeyinde yapılırsa, aynı fırtınanın farklı anları hem eğitim hem doğrulama kümesine dağılır ve model doğrulama sırasında pratikte daha önce gördüğü sahnelerle karşılaşır. Bu durum performansın yapay olarak yüksek ölçülmesine yol açar [14]. Bunu önlemek için eğitim/doğrulama ayrımı kare düzeyinde değil, olay kimliği (event id) düzeyinde ve sınıf oranları korunarak yapılmıştır. Bir olay eğitim kümesine atandığında o olaya ait bütün kareler eğitim tarafında, doğrulama kümesine atandığında ise bütün kareleri doğrulama tarafında yer almıştır.

Ayrıca oluşturulan bölme bilgisi diske kaydedilmiş ve hem eğitim hem değerlendirme aşamalarında aynı dosyadan okunmuştur. Bu sayede farklı mimarilerin karşılaştırılmasında ve tekrarlanan deneylerde bölmelerin farklılaşması ihtimali tamamen ortadan kaldırılmıştır.


Uygulanan filtreler sonucunda 1.124 tekil olay elde edilmiştir. Veri setinin yapısı Tablo 2’de verilmiştir. Her olaydan 9 kare alınmasıyla eğitim kümesi 8.091, doğrulama kümesi 2.025 görüntüden oluşmuştur. Böylece araştırma önerisinde 1. iş paketi için belirlenen "1.000+ görüntü" başarı ölçütü sağlanmıştır.

Küme	Olay sayısı	Oraj (1)	Normal (0)
Eğitim	899	529	370
Doğrulama	225	133	92
Toplam	1.124	662	462


Tablo 2. Olay bazlı bölme sonrasında veri setinin dağılımı.

Sınıflar arasındaki sayısal dengesizliği telafi etmek amacıyla eğitim kümesindeki oranlardan otomatik olarak hesaplanan sınıf ağırlıkları (normal sınıfı için 1,21, oraj sınıfı için 0,85) kayıp fonksiyonuna uygulanmıştır [17].

Kalıntı zamansal yanlılığın sınanması. Ortak zaman penceresi uygulanmasına rağmen, sınıfların pencere içindeki dağılımlarının tam olarak örtüşmediği gözlenmiştir; karşıt sınıf Haziran ayının ikinci yarısında yoğunlaşmaktadır. Bu kalıntı yanlılığın model başarımına etkisini sınamak amacıyla, her iki sınıfın da yeterli sayıda temsil edildiği dar zaman aralığında (yılın 139–178. günleri; doğrulama kümesindeki 440 oraj ve 380 normal görüntü, toplamın %73’ü) ROC-AUC değeri yeniden hesaplanmıştır. ResNet50 için tüm kümede 0,8227 olan AUC değeri dar pencerede 0,8250, DenseNet121 için ise 0,8062 yerine 0,8015 olarak ölçülmüştür. Farkların mutlak değeri her iki modelde de 0,005’in altında kalmıştır. Zamansal ipucunun büyük ölçüde ortadan kaldırılması başarımında düşüşe yol açmadığından, modellerin ayırt ediciliğinin olayların takvimsel konumuna değil görüntü içeriğine dayandığı sonucuna varılmıştır. Bu sınanmanın yalnızca mevsimsel yanlılığı ele aldığı, diğer olası karıştırıcı etkenleri kapsamadığı belirtilmelidir.



Şekil 2. Sınıfların yıl içindeki zamansal dağılımı.



Şekil 3. Doğrulama kümesinin zamansal dağılımı ve kalıntı yanlılık sınavasında kullanılan ortak pencere. Üstte ResNet50, altta DenseNet121.

2.4. Derin öğrenme modellerinin geliştirilmesi

Araştırma önerisinde ResNet, DenseNet ve YOLO mimarilerinin karşılaştırılması öngörülmüştü. Proje sürecinde YOLO mimarisinin bu problem için uygun olmadığı belirlenmiştir. YOLO bir nesne tespiti (object detection) mimarisi olup eğitimi için görüntü üzerinde hedef nesnenin konumunu belirten sınırlayıcı kutu (bounding box) etiketleri gerektirmektedir. SEVIR veri seti olay düzeyinde etiket sağlamakta; oraj bölgesinin görüntü içindeki koordinatlarını belirten kutu etiketleri içermemektedir. Bu etiketlerin uzman meteorolojik değerlendirmeyle elle üretilmesi proje kapsamı ve süresi dışında kalmıştır. Bu nedenle problem ikili sınıflandırma olarak kurgulanmış ve karşılaştırma ResNet50 ile DenseNet121 mimarileri arasında yapılmıştır.

Her iki mimari de ImageNet veri seti üzerinde önceden eğitilmiş ağırlıklarla başlatılmıştır [11]. Bu mimariler üç kanallı renkli görüntü girdisi beklemekte, çalışmada kullanılan termal görüntüler ise tek kanalıdır. Bu uyumsuzluğu gidermek için görüntüyü doğrudan üç kez kopyalamak yerine, ağırlık başına öğrenilebilir bir 3×3 evrişim katmanı yerleştirilmiştir. Böylece tek kanallı termal bilginin üç kanala nasıl dağıtılacağı da eğitim sırasında öğrenilmiştir.

Gövde ağının çıkışına küresel ortalama havuzlama (Global Average Pooling) katmanı, ardından %40 seyreltme oranına sahip iki düzenleme katmanı ve 256 nöronlu tam bağlı katman eklenmiştir. Çıkış katmanı, oraj olma olasılığını üreten tek nöronlu sigmoid aktivasyonlu katmandır. Kayıp fonksiyonu olarak ikili çapraz entropi kullanılmıştır.

2.5. Eğitim stratejisi ve hiperparametre optimizasyonu

Model eğitimi Google Colab platformunda NVIDIA T4 grafik işlemcisi üzerinde gerçekleştirilmiştir. Sınırlı büyüklükteki veri setlerinde önceden eğitilmiş ağırlıkların tamamının aynı anda serbest bırakılması eğitimi kararsızlaştırabildiğinden, iki aşamalı bir eğitim stratejisi uygulanmıştır:

- Aşama 1: Önceden eğitilmiş gövde tamamen dondurulmuş, yalnızca yeni eklenen sınıflandırma katmanları 1×10^{-3} öğrenme oranıyla eğitilmiştir. Bu aşamanın amacı, rastgele başlatılmış sınıflandırıcı katmanların gövdeye zarar vermeden makul bir başlangıç noktasına ulaşmasıdır.
- Aşama 2: Gövdenin yalnızca üst blokları serbest bırakılmış, toplu normalleştirme katmanları dondurulmuş hâlde tutulmuş ve 2×10^{-5} öğrenme oranıyla ince ayar yapılmıştır.


Bu stratejinin gerekliliği deneysel olarak gösterilmiştir. Proje kapsamında yapılan ilk eğitim denemesinde gövdenin tamamı tek seferde serbest bırakılmış ve toplu normalleştirme katmanları eğitime açık tutulmuştur. Bu koşuda doğrulama kaybı 18,8 seviyesine yükselmiş, modelin doğrulama kümesindeki duyarlılık değeri 1,000 ve kesinlik değeri 0,507 olarak ölçülmüştür. Bu değerler modelin bütün örnekleri ayırım yapmaksızın "oraj" olarak sınıflandırdığı, yani tamamen çöktüğü anlamına gelmektedir. Toplu normalleştirme katmanlarının dondurulması ve gövdenin kademeli olarak çözülmesi bu kararsızlığı tamamen ortadan kaldırmış, sonraki koşullarda doğrulama kaybı düzenli biçimde azalan bir seyir izlemiştir. Bu bulgu, küçük ölçekli veriyle transfer öğrenme uygulayan çalışmalar açısından pratik bir katkı niteliğindedir [12].

İnce ayar aşamasında serbest bırakılacak katman derinliği, her iki mimari için ön denemeler sonucunda belirlenmiştir. ResNet50 modelinde 175 katmandan 65'i (%37), DenseNet121 modelinde 427 katmandan 81'i (%19) eğitime açılmıştır. Mimarilerin katman yapıları farklı olduğundan serbest bırakılan katman oranları tam olarak eşitlenememiştir; bu durum karşılaştırmanın bir sınırlılığı olarak Bölüm 3.5'te ele alınmıştır.


Eğitim sürecinde ayrıca aşağıdaki düzenlemeler uygulanmıştır:

- Öğrenme oranı azaltma: Doğrulama kaybı iki devir boyunca iyileşmediğinde öğrenme oranı yarıya indirilmiştir.
- Erken durdurma: Doğrulama ROC-AUC değeri beş devir boyunca iyileşmediğinde eğitim sonlandırılmış ve en iyi devre ait ağırlıklar geri yüklenmiştir.
- Optimizasyon algoritması olarak Adam kullanılmış, yığın boyutu 16 olarak belirlenmiştir.

Eğitim süreçlerine ait başarımlar eğrileri Şekil 4 ve Şekil 5'te verilmiştir. ResNet50 modelinde doğrulama kaybının eğitimin son bölümünde hafif bir artış eğilimine girdiği gözlenmiştir. Erken durdurma ölçütü olarak ROC-AUC kullanıldığından ve bu değer artmaya devam ettiğinden eğitim sürdürülmüş; ancak en iyi ağırlıkların geri yüklenmesi sayesinde raporlanan sonuçlar bu aşamadan etkilenmemiştir. Bu gözlem, erken durdurma ölçütü seçiminin durdurma davranışını doğrudan etkilediğini göstermektedir.



Şekil 4. ResNet50 modeline ait eğitim ve doğrulama başarımları eğrileri.



Şekil 5. DenseNet121 modeline ait eğitim ve doğrulama başarımları eğrileri.

2.6. Optik akış ile bulut hareketlerinin analizi

Araştırma önerisinin 2. iş paketinde, ardışık uydu görüntülerinde bulut örüntülerinin hareket yönlerinin ve hızlarının optik akış yöntemiyle belirlenmesi öngörülmüştür. Bu kapsamda, aynı olaya ait ardışık kareler arasındaki hareket alanları Farneback optik akış algoritmasıyla hesaplanmıştır [18]. Her sınıftan 60 olay üzerinde, olay başına üç farklı zaman adımı örneklenerek beş öznitelik çıkarılmıştır: ortalama hareket hızı, 95. yüzdilik hız, bulutlu bölgelerdeki ortalama hız, hareket alanının diverjansı (yayılma) ve bulut kaplama oranı.

Diverjans özniteliği, konvektif sistemlerin örs (anvil) bölgesindeki yatay yayılmayı temsil ettiği için önceden fiziksel gerekçeyle seçilmiştir. Elde edilen sonuçlar Tablo 3'te verilmiştir.


Öznitelik	Normal (ort. $\pm$ ss)	Oraj (ort. $\pm$ ss)	p değeri
Ortalama hız (px/kare)	1,365 $\pm$ 0,751	1,620 $\pm$ 0,882	0,2106
95. yüzdilik hız	2,920 $\pm$ 1,274	3,435 $\pm$ 1,371	0,0506
Bulutlu bölge hızı	1,518 $\pm$ 0,935	1,874 $\pm$ 0,993	0,0756
Yayılma (diverjans)	0,056 $\pm$ 0,019	0,072 $\pm$ 0,023	0,0004
Bulut kaplama oranı	0,309 $\pm$ 0,292	0,356 $\pm$ 0,229	0,1032

Tablo 3. Optik akış özniteliklerinin sınıflara göre karşılaştırılması (Mann-Whitney U testi, sınıf başına 60 olay).


Beş özniteliğin tamamında oraj sınıfı ortalamaları normal sınıfından yüksek bulunmuştur. Konvektif örs yayılmasını temsil eden diverjans özniteliğinde $p = 0,0004$ değeri elde edilmiş olup, bu sonuç beş ayrı karşılaştırma için Bonferroni düzeltmesi uygulandığında dahi

(düzeltilmiş anlamlılık düzeyi $\alpha = 0,01$) istatistiksel anlamlılığını korumaktadır. Söz konusu öznitelik için hesaplanan etki büyüklüğü Cohen's $d \approx 0,76$ olup orta-büyük düzeydedir. Doksan beşinci yüzdilik hız özniteliği $p = 0,0506$ ile sınırda kalmış, diğer öznitelikler anlamlılık düzeyine ulaşmamıştır.

Bu bulgu, oraj olaylarında bulut alanının daha hızlı yayıldığını ve bulut hareket bilgisinin sınıflandırma için ayırt edici bir öznitelik oluşturabileceğini göstermektedir. Ancak çıkarılan öznitelikler, proje süresi içerisinde sınıflandırma modeline girdi olarak entegre edilememiştir. Bu nedenle araştırma önerisinde bu iş paketi için belirlenen "bulut hareketlerinin %90 doğrulukla modellenmesi" ölçütüne ulaşılammış; iş paketi kısmen gerçekleştirilmiş olarak değerlendirilmiştir.



Şekil 6. Ardışık uydu görüntülerinden optik akış ile bulut hareketinin çıkarılması. Üst sıra: oraj olayı, alt sıra: normal olay.



Şekil 7. Optik akış özniteliklerinin sınıflara göre dağılımı.

2.7. Performans değerlendirme protokolü

Modellerin performansı, eğitim sürecinde hiçbir karesi kullanılmamış olaylardan oluşan doğrulama kümesi üzerinde ölçülmüştür. Değerlendirme sırasında veri artırma uygulanmamış

ve kare seçimi deterministik yapılmıştır. Değerlendirme aşamasında olay başına 5 kare kullanılmış olup, 225 doğrulama olayından toplam 1.125 görüntü (665 oraj, 460 normal) elde edilmiştir.

Eğitim ve eğitim sırasındaki izleme aşamasında olay başına 9 kare kullanılmışken, nihai performans değerlendirmesi 5 kare üzerinden yapılmıştır. Değerlendirmede kullanılan 5 kare, eğitimde kullanılan 9 karenin bir alt kümesi olup olay süresi boyunca eşit aralıklarla dağılmıştır; dolayısıyla iki küme arasında olay veya zaman aralığı farkı bulunmamaktadır. Kare sayısının azaltılmasının gerekçesi, aynı olaya ait ardışık karelerin birbirleriyle yüksek korelasyona sahip olması ve raporlanan ölçütlerin bu iç bağımlılıktan daha az etkilenmesinin amaçlanmasıdır. Eğitim sürecinde izlenen doğrulama ROC-AUC değerleri ile Tablo 4'te raporlanan değerler arasındaki küçük farklar bu kare sayısı farkından kaynaklanmaktadır.

Sınıf dağılımının tam dengeli olmaması nedeniyle yalnızca genel doğruluk ölçütünün kullanılmasının yanıltıcı olabileceği değerlendirilmiş [17] ve aşağıdaki tamamlayıcı ölçütlerden yararlanılmıştır: kesinlik (precision), duyarlılık (recall), F1 skoru (sınıf bazında ve makro ortalama), ROC-AUC [19] ve karışıklık matrisi. Ayrıca karar eşiğinin performansa etkisi ayrıca incelenmiştir (Bölüm 3.2).

3. Sonuç

Bu projede, meteoroloji uydularından elde edilen termal kızılötesi görüntüler üzerinde derin öğrenme yöntemleri kullanılarak oraj içeren ve içermeyen atmosferik durumları ayırt edebilen bir sınıflandırma yaklaşımı geliştirilmiştir. Çalışmada orajın alt türleri veya şiddet dereceleri sınıflandırılmamış; görüntü, oraj içeren bir olaya ait olup olmaması bakımından ikili olarak değerlendirilmiştir.

3.1. Sınıflandırma sonuçları

Doğrulama kümesi üzerinde varsayılan karar eşiği (0,50) ile elde edilen sonuçlar Tablo 4'te verilmiştir.

Performans ölçütü	ResNet50	DenseNet121	Hedef
Doğruluk	0,722	0,742	0,90
ROC-AUC	0,8227	0,8062	—
Kesinlik (Oraj)	0,808	0,791	—
Duyarlılık (Oraj)	0,695	0,767	—
F1 skoru (Oraj)	0,747	0,779	0,85
Kesinlik (Normal)	0,633	0,677	—
Duyarlılık (Normal)	0,761	0,707	—
F1 skoru (Normal)	0,691	0,691	—
F1 skoru (makro ort.)	0,719	0,735	—

Tablo 4. Doğrulama kümesi üzerinde varsayılan karar eşiği (0,50) ile elde edilen performans.


Sonuçlar iki mimarinin farklı ölçütlerde öne çıktığını göstermektedir. ResNet50 modeli ROC-AUC ölçütünde (0,8227) DenseNet121'den (0,8062) üstündür; buna karşılık varsayılan eşikte hesaplanan doğruluk ve F1 skorlarında DenseNet121 daha yüksek değerler üretmiştir. Bu görünürdeki çelişkinin nedeni, iki ölçüt ailesinin farklı özellikleri ölçmesidir. ROC-AUC eşikten bağımsız bir ölçüt olup modelin örnekleri doğru sıralama kabiliyetini değerlendirirken, doğruluk ve F1 skoru sabit bir karar eşiğinde hesaplandığından modelin ürettiği olasılıkların bu eşığe göre konumlanmasına da bağlıdır. Bu bulgu, karar eşiğinin ayrıca incelenmesi gerektiğini göstermiş ve Bölüm 3.2'de sunulan analiz bu gerekçeyle yapılmıştır.

Karışıklık matrisleri Tablo 5'te verilmiştir. Varsayılan eşikte ResNet50 modeli 665 oraj görüntüsünün 203'ünü, DenseNet121 ise 155'ini kaçırmıştır.


ResNet50	Tahmin: Normal	Tahmin: Oraj
Gerçek: Normal	350	110
Gerçek: Oraj	203	462
DenseNet121	Tahmin: Normal	Tahmin: Oraj
Gerçek: Normal	325	135

Gerçek: Oraj	155	510
--------------	-----	-----

Tablo 5. Karışıklık matrisleri (karar eşiği 0,50).




Şekil 8. ResNet50 modeline ait karışıklık matrisi.



Şekil 9. DenseNet121 modeline ait karışıklık matrisi.


ROC eğrileri Şekil 10'da karşılaştırmalı olarak verilmiştir. Rastgele tahmin üreten bir modelin ROC-AUC değeri 0,500 olacağından, elde edilen 0,82 ve 0,81 düzeyindeki değerler

modellerin veriden anlamlı bir ayırım öğrendiğini ortaya koymaktadır. ResNet50 modelinin üstünlüğü özellikle düşük yanlış alarm oranı bölgesinde (0–0,2 aralığında) belirginleşmektedir. Bu bölge, bir erken uyarı sisteminin gerçek kullanımda çalıştırılacağı aralık olduğundan operasyonel açıdan önem taşımaktadır.



Şekil 10. ResNet50 ve DenseNet121 modellerine ait ROC eğrileri.

Modellerin yanlış alarm ürettiği örnekler ayrıca incelenmiştir. Şekil 11’de, veri setinde normal olarak etiketlenmiş ancak model tarafından yüksek olasılıkla (0,80 üzeri) oraj olarak sınıflandırılmış görüntüler yer almaktadır. Bu görüntüler, oraj sınıfına ait örneklerden görsel olarak ayırt edilemeyen, geniş ve düşük sıcaklıklı bulut tepesi yapıları içermektedir. Bu gözlem, yanlış alarmların bir bölümünün modelin ayırt etme hatasından değil, veri setinin etiketleme yönteminden kaynaklanabileceğine işaret etmiş; bu olasılık Bölüm 3.3’te bağımsız bir veri kaynağıyla nicel olarak sınanmıştır.



Şekil 11. Normal olarak etiketlenmiş, ancak model tarafından yüksek olasılıkla oraj olarak sınıflandırılan görüntüler.

3.2. Karar eşiği optimizasyonu ve model seçimi

Bölüm 3.1’de belirtildiği üzere, varsayılan 0,50 karar eşiği modellerin ürettiği olasılık dağılımları için en uygun kesme noktası olmayabilir. Bu nedenle 0,05–0,95 aralığında 91 farklı eşik değeri için kesinlik, duyarlılık, F1 skoru ve doğruluk yeniden hesaplanmıştır. Sonuçlar Tablo 6’da özetlenmiştir.


Yapılandırma	Eşik	F1 (Oraj)	Duyarlılık	Doğruluk
ResNet50 — varsayılan	0,50	0,747	0,695	0,722
ResNet50 — en iyi F1	0,34	0,817	0,890	0,764
ResNet50 — duyarlılık $\geq 0,90$	0,33	0,816	0,901	—
DenseNet121 — varsayılan	0,50	0,779	0,767	0,742
DenseNet121 — en iyi F1	0,39	0,815	0,890	0,762

Tablo 6. Karar eşiği optimizasyonu sonuçları.

Eşik optimizasyonu her iki modelde de belirgin bir iyileşme sağlamıştır. ResNet50 modelinde F1 skoru 0,747’den 0,817’ye, doğruluk ise 0,722’den 0,764’e yükselmiştir. Kaçırılan oraj sayısı 203’ten 73’e inmiş, yani yaklaşık %64 oranında azalmıştır. Duyarlılığın 0,90 düzeyine sabitlendiği yapılandırmada kaçırılan oraj sayısı 66’ya kadar düşmektedir.

Eşik düşürüldüğünde yalnızca F1 skorunun değil doğruluğun da artması dikkat çekicidir; bu durum 0,50 eşiklerinin incelenen ölçütlerin hiçbirisi için en uygun değer olmadığını göstermektedir. Bunun bir nedeni, eğitim sırasında uygulanan sınıf ağırlıklandırmasının modeli oraj tahmininden görece caydırması, buna karşılık doğrulama kümesinde oraj sınıfının çoğunluğu (%59) oluşturmasıdır.

Eşik optimizasyonunun doğrulama kümesi üzerinde yapılmış olması, ayrı bir ayar kümesi bulunmadığından, elde edilen değerlerin bir miktar iyimser olabileceği anlamına gelmektedir. Ancak Şekil 12’de görüldüğü üzere ResNet50 modelinin F1 eğrisi yaklaşık 0,28–0,45 aralığında geniş bir plato oluşturmakta ve bu aralık boyunca 0,80’in üzerinde kalmaktadır. Keskin bir tepe noktası yerine geniş bir platonun gözlenmesi, seçilen eşik gürültüye aşırı uyum sonucu belirlenmediğine işaret etmektedir.



Şekil 12. Karar eşiğinin model başarımına etkisi.

Model seçimi. Optimize edilmiş eşik değerleriyle karşılaştırıldığında ResNet50 modeli F1 skoru (0,817'ye karşılık 0,815) ve doğruluk (0,764'e karşılık 0,762) bakımından DenseNet121'in bir miktar önünde yer almaktadır. Eşikten bağımsız ayırt edicilik ölçütü olan ROC-AUC değerinde ise fark daha belirgindir (0,8227'ye karşılık 0,8062). Ayrıca ResNet50'nin düşük yanlış alarm oranı bölgesindeki üstünlüğü, sistemin operasyonel olarak çalıştırılacağı aralıkta avantaj sağlamaktadır. Bu nedenlerle proje çıktısı olarak ResNet50 mimarisi, 0,34 karar eşiğiyle birlikte seçilmiştir. Ancak iki model arasındaki farkın küçük olduğu ve tek eğitim koşusuna dayandığı göz önünde bulundurulmalıdır.

3.3. Etiket kalitesinin bağımsız değerlendirilmesi

Bölüm 3.1'de yanlış alarm örneklerinin incelenmesi, veri setindeki etiketlerin bir bölümünün meteorolojik gerçeklikle örtüşmeyebileceğine işaret etmiştir. Bu olasılığı nicel olarak sınamak amacıyla, SEVIR arşivinin yıldırım kanalı bağımsız bir doğrulama kaynağı olarak kullanılmıştır.

Meteorolojik tanım gereği oraj, yıldırım ve gök gürültüsü üreten konvektif fırtına olarak tanımlanmaktadır. Dolayısıyla bir olay penceresinde kaydedilen yıldırım sönme sayısı, etiket tutarlılığı için doğrudan ve nesnel bir ölçüt oluşturmaktadır. Veri setindeki 1.124 olayın tamamı yıldırım kayıtlarıyla eşleştirilebilmiş, hiçbir olay eşleşme dışında kalmamıştır. Elde edilen sonuçlar Tablo 7 ve Tablo 8'de verilmiştir.

Sınıf	Olay sayısı	Ortalama sönme	Medyan sönme
Normal (0)	462	4.747,5	1.686,0
Oraj (1)	662	10.874,9	7.580,5

Tablo 7. Sınıflara göre yıldırım aktivitesi.

Oraj sınıfında medyan sönme sayısı, karşıt sınıfın yaklaşık dört buçuk katıdır ve aradaki fark istatistiksel olarak yüksek düzeyde anlamlıdır (Mann-Whitney U testi, $p = 9,5 \times 10^{-45}$). Bu sonuç, kullanılan etiketlemenin meteorolojik açıdan tutarlı bir yönelim taşıdığını göstermektedir.

Bununla birlikte, karşıt sınıfa ait olayların önemli bir bölümünde yoğun yıldırım aktivitesi kaydedilmiştir. Farklı eşik değerleri için hesaplanan oranlar ve bu oranlardan türetilen azami ulaşılabilir doğruluk değerleri Tablo 8'de verilmiştir.


Yıldırım eşiği	Oraj sınıfı (%)	Normal sınıfı (%)	Gerçekten sakin (%)	Azami doğruluk
≥ 1 sönme	99,4	85,9	14,1	—
≥ 100 sönme	97,4	73,2	26,8	%68,4
≥ 500 sönme	94,6	61,0	39,0	%71,7
≥ 1.000 sönme	90,8	54,8	45,2	%72,1
≥ 5.000 sönme	64,2	31,8	68,2	%65,8

Tablo 8. Yıldırım eşiğine göre etiket tutarlılığı ve azami ulaşılabilir doğruluk tahmini.

Karşıt sınıfa ait olayların %73,2'sinde yüzden fazla yıldırım sönmesi kaydedilmiştir. Bu oran, karşıt sınıfın meteorolojik olarak sakin durumları temsil etmediğini ortaya koymaktadır. İlgili yıldırım eşiği gerçek etiket kabul edildiğinde, fiziksel olarak kusursuz çalışan bir tespit sisteminin mevcut etiketlere göre ulaşabileceği azami doğruluk %68,4 olarak hesaplanmaktadır. Eşik değeri elli kat değiştirildiğinde dahi bu tahmin %66–72 bandında kalmakta, dolayısıyla bulgu eşik seçiminden bağımsız görünmektedir.

Karşıt sınıfın yıldırım aktivitesi dağılımı iki tepeli bir yapı sergilemektedir: olayların yalnızca %14,1'inde hiç yıldırım kaydedilmemiş, kalan bölüm ise oraj sınıfının dağılımıyla büyük ölçüde örtüşmüştür. Bu durum, karşıt sınıfın homojen bir kategori olmadığını; meteorolojik olarak sakin durumlar ile NOAA Storm Events veri tabanına raporlanmamış konvektif olayların karışımından oluştuğunu göstermektedir.

Bu bulgunun yorumlanmasında iki sınırlılık göz önünde bulundurulmalıdır. Birincisi, yıldırım sayımları 384 × 384 km'lik olay penceresinin tamamı için toplanmaktadır; dolayısıyla yüksek sönme sayısı, fırtınanın modele verilen görüntü kesitinde bulunduğunu kesin olarak kanıtlamaz. İkincisi, oraj olarak etiketlenmiş olayların küçük bir bölümünde de hiç yıldırım kaydedilmemiştir; bunun nedeni NOAA Storm Events veri tabanının sel ve kuvvetli rüzgâr gibi oraj dışı olay türlerini de içermesidir. Etiket gürültüsü çift yönlü olmakla birlikte karşıt sınıfta belirgin biçimde daha yoğundur.



Şekil 13. Etiket kalitesinin yıldırım verisiyle doğrulanması.

3.4. Proje hedeflerinin gerçekleşme düzeyi

Araştırma önerisinde belirlenen hedeflerin gerçekleşme durumu Tablo 9'da değerlendirilmiştir.

Proje hedefi	Gerçekleşme durumu	Açıklama
Uydu görüntülerinden veri seti oluşturulması (1.000+ görüntü)	Gerçekleştirildi	1.124 tekil olaydan 10.116 görüntü elde edilmiştir.
Görüntü ön işleme adımlarının uygulanması	Gerçekleştirildi	Fiziksel birime dönüştürme, normalizasyon, zamansal örnekleme ve veri artırma uygulanmıştır.
ResNet ve DenseNet mimarilerinin karşılaştırılması	Gerçekleştirildi	Her iki mimari aynı bölme ve protokol altında eğitilmiştir.

YOLO mimarisinin değerlendirilmesi	Gerçekleştirilemedi	Nesne tespiti mimarisi olduğundan sınırlayıcı kutu etiketi gerektirmekte, veri setinde bu etiketler bulunmamaktadır.
Optik akış ile bulut hareketlerinin izlenmesi	Kısmen gerçekleştirildi	Hareket öznitelikleri çıkarılmış ve istatistiksel olarak karşılaştırılmış; sınıflandırma modeline entegre edilememiştir.
Hiperparametre optimizasyonu ile doğruluğun artırılması	Gerçekleştirildi	Karar eşiği optimizasyonu ile F1 skoru 0,747'den 0,817'ye yükseltilmiştir.
Model performansında %90 üzeri doğruluk	Gerçekleştirilemedi	ResNet50 ile optimize eşikte %76,4 doğruluk elde edilmiştir.
0,85 üzeri F1 skoru	Kısmen gerçekleştirildi	Oraj sınıfı için 0,817 F1 skoru elde edilmiştir.
Sonuçların görselleştirilmesi	Gerçekleştirildi	Karışıklık matrisi, ROC eğrisi, başarımlar eğrileri ve örnek görüntü analizleri üretilmiştir.
Kullanıcı dostu arayüz geliştirilmesi	Gerçekleştirildi	Web tabanlı etkileşimli bir demo arayüzü geliştirilmiştir (Bölüm 4).
Bilimsel makale yayımlanması	Gerçekleştirilemedi	Proje süresi içerisinde yayın gerçekleştirilememiştir.

Tablo 9. Araştırma önerisindeki hedeflerin gerçekleştirme durumu.

Araştırma önerisinde belirlenen %90 doğruluk hedefine ulaşamamıştır. ResNet50 mimarisiyle optimize edilmiş karar eşiğinde %76,4 doğruluk ve 0,817 F1 skoru elde edilmiştir. Dolayısıyla projenin nicel başarı ölçütleri bakımından hedeflerin tam olarak sağlandığı söylenemez. Ancak Bölüm 3.3'te sunulan analiz, bu hedefin kullanılan veri setinin etiketleme şemasıyla ulaşılabilir olmadığını nicel olarak ortaya koymaktadır: fiziksel olarak kusursuz çalışan bir sistemin dahi mevcut etiketlere göre ölçülen doğruluğunun %66–72 bandında kalacağı hesaplanmıştır. Elde edilen %76,4 değeri bu bandın üzerindedir.

Bu noktada önemli bir metodolojik değerlendirmenin yapılması gerekmektedir. Proje sürecinde, Bölüm 2.3'te açıklanan ortak zaman penceresi kısıtı ve olay bazlı bölme uygulanmadığında ölçülen başarımın belirgin biçimde yükseldiği gözlenmiştir. Ancak bu yükselişin kaynağı modelin oraj tespitindeki gerçek yeteneği değil, mevsimsel arka plan sıcaklığı farkı ile aynı olaya ait karelerin eğitim ve doğrulama kümelerine dağılmasıdır. Bu tür yapay başarı kaynakları bilinçli olarak ortadan kaldırıldığında ölçülen performans düşmüş, ancak elde edilen değer modelin gerçek genelleme kabiliyetini yansıtan bir değere dönüşmüştür. Raporda sunulan bütün sonuçlar bu kısıtlar altında elde edilmiştir.

3.5. Genel değerlendirme, sınırlılıklar ve gelecek çalışmalar

Genel olarak değerlendirildiğinde, proje kapsamında önerilen derin öğrenme tabanlı oraj tespiti yaklaşımının temel bileşenleri geliştirilmiş ve çalışır durumda ortaya konmuştur. Uydu kaynaklı termal görüntülerden veri hattı kurulmuş, iki farklı derin öğrenme mimarisi aynı

protokol altında eğitilmiş, karar eşiği optimize edilmiş ve performansları bilimsel olarak savunulabilir bir değerlendirme düzeniyle ölçülmüştür.

Havacılık güvenliği bağlamında model davranışının değerlendirilmesi de önem taşımaktadır. Seçilen yapılandırmada oraj sınıfı için duyarlılık 0,890 düzeyindedir; yani modelin kararsız kaldığı durumlarda oraj yönünde karar verme eğilimi bulunmaktadır. Bu asimetri bir kusur değil, uygulama bağlamına uygun bilinçli bir tasarım tercihidir: tespit edilemeyen bir konvektif sistem doğrudan uçuş güvenliği riski oluştururken, yanlış alarmin maliyeti yalnızca gereksiz bir uyarı ve ek meteorolojik kontroldür.

Çalışmanın en önemli sınırlılığı etiket gürültüsüdür. Bölüm 3.3'te nicel olarak gösterildiği üzere, karşıt sınıf oraj içermediği doğrulanmış görüntülerden değil, rastgele seçilmiş görüntülerden oluşmakta ve bu olayların %73,2'sinde yoğun yıldırım aktivitesi bulunmaktadır. Karşıt sınıfın meteorolojik olarak sakın oldukları doğrulanmış görüntülerden oluşturulması, başarıyı doğrudan artıracaktır.

İkinci önemli sınırlılık, modelin her seferinde tek bir zaman adımını değerlendirmesidir. Oysa konvektif gelişimin en ayırt edici özelliği zaman içindeki değişimdir: bulut tepesi sıcaklığının hızlı düşüşü, dikey gelişimin hızı ve bulut alanının genişleme oranı, tek bir kareye bakarak elde edilemeyecek bilgilerdir. Bölüm 2.6'da optik akış analiziyle elde edilen bulgular, bu bilginin ayırt edici olduğunu desteklemektedir; ancak söz konusu öznitelikler proje süresi içinde modele entegre edilememiştir.

Üçüncü sınırlılık veri hacmidir. Mevsimsel yanlılığı gidermek için uygulanan ortak zaman penceresi kısıtı, kullanılabilir olay sayısını 1.124'e düşürmüştür. Bu, derin mimarilerin tam kapasiteyle eğitilmesi için sınırlı bir hacimdir.

Dördüncü olarak, iki mimarinin karşılaştırılmasında ince ayar derinlikleri tam olarak eşitlenememiştir. Mimarilerin katman yapıları farklı olduğundan, aynı blok adından itibaren çözme uygulanmasına rağmen serbest bırakılan katman oranları ResNet50 için %37, DenseNet121 için %19 olmuştur. Ayrıca her iki model için tek eğitim koşusu gerçekleştirildiğinden, aradaki küçük farkların rastgele ağırlık başlatmasından kaynaklanma olasılığı dışlanamaz.

Beşinci olarak, kullanılan SEVIR veri seti Amerika Birleşik Devletleri kıta topraklarını kapsamaktadır. Projenin motivasyonu Türkiye'deki havacılık güvenliği olmakla birlikte, model Türkiye üzerindeki atmosferik koşullarda doğrudan test edilmemiştir.

Son olarak, çalışma tamamen çevrimdışı olarak, kayıtlı uydu görüntüleri üzerinde yürütülmüştür. Gerçek zamanlı veri akışının alınması, meteorolojik karar destek sistemleriyle bütünleştirme ve operasyonel koşullarda çevrim içi test gerçekleştirilmemiştir. Bu nedenle elde edilen sonuçlar, doğrudan kullanıma hazır bir uyarı sistemi olarak değil, geliştirilmeye açık bir prototip olarak değerlendirilmelidir.

Gelecek çalışmalar için öngörülen adımlar şunlardır:

- Karşıt sınıfın yıldırım verisi kullanılarak yeniden tanımlanması: Meteorolojik tanım gereği oraj yıldırım üreten konvektif fırtına olduğundan, olay penceresindeki yıldırım sönme sayısına dayalı bir etiketleme, raporlama yanlılığından bağımsız ve fiziksel

olarak daha tutarlı bir denetim sinyali sağlayacaktır. Böyle bir çalışmada eşik değerin gerekelendirilmesi ve eşik duyarlılık analizinin sunulması gerekmektedir.

- Ardışık kareleri birlikte değerdendiren zamansal modellerin (3B evrişim, CNN-LSTM veya dönüştürücü tabanlı mimariler) kullanılması.
- Bölüm 2.6'da çıkarılan optik akış özniteliklerinin, özellikle diverjans özniteliğinin, sınıflandırma modeline ek girdi olarak verilmesi.
- Termal kızılötesi, görünür ve radar türetimli kanalların çok kanallı biçimde birleştirilmesi.
- Türkiye ve çevresini kapsayan uydu verileriyle (örneğin MSG/SEVIRI) modelin yerel koşullarda doğrulanması.
- Sınırlayıcı kutu etiketlerinin üretilmesi hâlinde nesne tespiti mimarilerinin değerdendirilerek orajın görüntü içindeki konumunun da belirlenmesi.

4. Çıktılar (Yayınlar, sunumlar v.b.)

Proje sonucunda, uydu kaynaklı termal kızılötesi görüntülerin oraj içeren ve içermeyen durumlar olarak sınıflandırılmasına yönelik, uçtan uca çalışan bir derin öğrenme yazılım prototipi geliştirilmiştir. Geliştirilen sistem; veri kataloğunun oluşturulması, geçerlilik denetimi, fiziksel birime dönüştürme ve normalizasyon, zamansal örnekleme, veri artırma, olay bazlı bölme, model eğitimi, karar eşiği optimizasyonu ve performans değerlendirmesi aşamalarını kapsamaktadır.

Projenin başlıca teknik çıktısı, mevsimsel yanlılık kontrolü ve olay bazlı doğrulama düzeni içeren, yeniden üretilebilir bir sınıflandırma işlem hattıdır. Bu işlem hattında bölme bilgisi diske kaydedilerek tüm modellerin ve değerlendirmelerin aynı ayrımı kullanması garanti altına alınmış; böylece yalnızca yüksek bir performans değeri elde edilmesi değil, sonuçların bilimsel açıdan savunulabilir biçimde raporlanması amaçlanmıştır. Proje kapsamında elde edilen somut çıktılar Tablo 10'da özetlenmiştir.


Projede geliştirilen tüm kaynak kodlar, veri hattı, model eğitimi ve değerlendirme betikleri, optik akış ve yıldırım tabanlı etiket doğrulama analizleri ile analiz not defteri açık erişimli bir depoda yayımlanmıştır: <https://github.com/Soresta/Thunderstorm-Detection-Satellite-IR-Tubitak>. Depo, raporda kullanılan olay bazlı bölme dosyasını (split_event_level.json) da içermektedir; bu sayede Tablo 2'de verilen eğitim/doğrulama ayrımı ve bu ayrıma dayanan bütün sonuçlar bağımsız olarak yeniden üretilebilmektedir.

Çıktı türü	Elde edilen çıktı	Açıklama
Veri çıktısı	Düzenlenmiş uydu görüntüsü veri seti	Oraj ve normal olarak etiketlenmiş 1.124 olay, ortak zaman penceresi kısıtı ve geçerlilik denetimi uygulanarak düzenlenmiştir.
Görüntü işleme çıktısı	Ön işleme ve normalizasyon yöntemi	SEVIR ölçekleme katsayılarının uygulanması, sıcaklık tabanlı ters normalizasyon ve zamansal örnekleme adımları geliştirilmiştir.
Değerlendirme çıktısı	Olay bazlı bölme protokolü ve yanlılık sınaması	Aynı olaya ait karelerin kümelere dağılması önlenmiş; kalıntı zamansal yanlılık nicel olarak sınanmıştır.
Model çıktısı	Eğitilmiş sınıflandırma modelleri	ResNet50 ve DenseNet121 mimarileri aynı protokol altında eğitilmiş ve ağırlıkları kaydedilmiştir.
Yöntem çıktısı	Kararlı transfer öğrenme stratejisi	İki aşamalı eğitim ve toplu normalleştirme katmanlarının dondurulmasıyla küçük veride kararlı ince ayar sağlanmıştır.
Optimizasyon çıktısı	Karar eşiği analizi	F1 skoru 0,747'den 0,817'ye yükseltilmiş, kaçırılan oraj sayısı %64 azaltılmıştır.


Doğrulama çıktısı	Etiket kalitesi analizi	Yıldırım verisiyle etiket tutarlılığı ölçülmüş ve doğruluk tavanı tahmin edilmiştir.
Arayüz çıktısı	Etkileşimli demo uygulaması	Web tabanlı bir arayüz geliştirilmiş; kullanıcı seçilen olay ve zaman adımı için model tahminini görüntüleyebilmektedir.
Raporlama çıktısı	Performans tabloları ve görseller	Karışıklık matrisi, ROC eğrisi, başarımlar eğrileri, eşik analizi ve yanlış alarm incelemeleri üretilmiştir.
Yazılım çıktısı	Açık erişimli kod deposu	Veri hattı, model eğitimi, değerlendirme, optik akış ve etiket doğrulama betiklerinin tamamı ile olay bazlı bölme dosyası açık erişimli olarak yayımlanmıştır.

Tablo 10. Proje kapsamında elde edilen başlıca çıktılar.

Geliştirilen arayüz, modelin doğrulama kümesinden seçilen olaylar üzerindeki tahminlerini, oraj olasılığını ve kullanılan karar eşiğini birlikte görüntülemektedir. Arayüze ait ekran görüntüleri Şekil 14 ve Şekil 15'te verilmiştir.



Şekil 14. Geliştirilen demo arayüzünde doğru tespit edilmiş bir oraj olayı.



Şekil 15. Demo arayüzünde normal olarak etiketlenmiş bir olayın değerlendirilmesi.

Çalışmanın bir diğer önemli çıktısı, proje ekibinin uzaktan algılama, görüntü işleme ve derin öğrenme alanlarında uygulamalı deneyim kazanmasıdır. Proje süresince büyük ölçekli meteorolojik veri setlerinin bulut ortamından edinilmesi, HDF5 biçimindeki çok boyutlu verilerin işlenmesi, TensorFlow/Keras ile model geliştirme, transfer öğrenme, sınıf dengesizliğinin yönetimi, istatistiksel hipotez testi ve performans değerlendirmesi konularında uygulamalı çalışmalar yürütülmüştür.

Proje süresi içerisinde sonuçlara dayalı yayımlanmış bir makale, sunulmuş bir konferans bildirisi veya gerçekleştirilmiş bir patent başvurusu bulunmamaktadır. Bununla birlikte elde edilen yöntem, deney sonuçları ve hazırlanan görseller, uydu görüntülerinden konvektif olay tespitinde metodolojik yanlışlıkların önlenmesini ve etiket kalitesinin başarımlar üzerindeki etkisini ele alan bir bildiri veya araştırma makalesinin hazırlanmasında kullanılabilecek düzeye getirilmiştir. Yayın gerçekleştirildiği takdirde çıktı bilgileri BİDEB Başvuru ve İzleme Sistemi'ne yüklenecek ve yayında TÜBİTAK 2209-A programı desteği belirtilecektir.

Proje çalışmalarının yürütülmesi sırasında kod geliştirme ve metin düzenleme aşamalarında üretken yapay zekâ araçlarından yararlanılmıştır. Üretilen tüm içeriğin doğruluğu, özgünlüğü ve bilimsel geçerliliği proje yürütücüsü ve akademik danışman tarafından kontrol edilmiştir.

5. Proje ile ilgili harcama kalemleri hakkında ayrıntılı bilgi

Araştırma önerisinde, projenin geliştirme giderlerinin karşılanması amacıyla sarf malzeme kaleminde 9.000 TL bütçe talebinde bulunulmuş ve bu tutar desteklenmiştir. Talep gerekçesinde bulut tabanlı hesaplama ve veri erişim hizmetlerinin kullanılacağı belirtilmiştir.

Proje kapsamında, kod geliştirme ve veri işleme aşamalarında kullanılmak üzere üretken yapay zekâ tabanlı bir yazılım hizmeti aboneliği (ChatGPT Plus) edinilmiştir. Söz konusu abonelik, `sevir_pipeline.py` ve `ek_calismalar.py` modüllerinin geliştirilmesi ile hata ayıklama süreçlerinde kullanılmıştır. Harcamalara ilişkin faturalar proje yürütücüsü Akif Karaca adına düzenlenmiş olup, fatura bilgileri e-BİDEB "Fatura ve Harcama Bilgileri" sekmesine girilmiştir.

Harcama süresi içinde (28.01.2026, 12.02.2026 ve 12.03.2026 tarihli faturalarla) toplam **3234,97 TL** tutarında harcama belgelendirilmiştir. Kalan **5765,03TL** tutarındaki destek kullanılmamış veya belgelendirilememiş olup, 26 / 07 / 2026 tarihinde TÜBİTAK Strateji Geliştirme Daire Başkanlığı hesabına iade edilmiştir. İade dekontu sisteme yüklenmiştir.

Harcama türü	Planlanan tutar	Gerçekleşen tutar	Açıklama
Sarf malzeme	9.000 TL	3234,97	ChatGPT Plus aboneliği
Makine/teçhizat	—	—	Harcama yapılmamıştır.
Hizmet alımı	—	—	Harcama yapılmamıştır.
Ulaşım	—	—	Harcama yapılmamıştır.
Toplam	9.000 TL	3234,97 TL	

Tablo 11. Proje kapsamında gerçekleşen harcamalar.

6. Kaynakça

- [1] M. Keskin and B. Efe, "Samsun Çarşamba Airport Analysis of Wind, Thunderstorm and Snow," presented at the International Engineering and Natural Sciences Conference (IENSC 2020), Dicle University, Diyarbakır, Turkey, Nov. 5–6, 2020.
- [2] S. Yazmuhammedov, A. Deniz, and E. T. Özdemir, "İstanbul Havalimanlarının CB ve Oraj Analizi," presented at the V. Ulusal Havacılık ve Uzay Konferansı (UHUK-2014), Erciyes Üniversitesi, Kayseri, Türkiye, Sep. 8–10, 2014.
- [3] E. Kessler, *The Thunderstorm in Human Affairs*. Norman, OK, USA: University of Oklahoma Press, 1983, pp. 125–146.
- [4] D. C. Pearson, "VFR Flight Not Recommended: A Study of Weather-Related Fatal Aviation Accidents," Technical Attachment SR SSD, no. 18, 2002.
- [5] Y. Zhang, S. Wistar, J. Li, M. A. Steinberg, and J. Z. Wang, "Severe Thunderstorm Detection by Visual Learning Using Satellite Images," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 47, no. 12, pp. 4029–4040, Dec. 2009.
- [6] S. Yazmuhammedov, A. Deniz, and E. T. Özdemir, "İstanbul Havalimanlarının CB ve Oraj Analizi," presented at the V. Ulusal Havacılık ve Uzay Konferansı (UHUK-2014), Erciyes Üniversitesi, Kayseri, Türkiye, Sep. 8–10, 2014, p. 4.
- [7] P. Bauer, A. Thorpe, and G. Brunet, "The Quiet Revolution of Numerical Weather Prediction," *Nature*, vol. 525, pp. 47–55, 2015, doi: 10.1038/nature14956.
- [8] X. Wang, R. Liao, J. Li, J. He, G. Wang, Z. Xu, and H. Wang, "Thunderstorm Identification Algorithm Research Based on Simulated Airborne Weather Radar Reflectivity Data," *Advances in Aerodynamics*, vol. 3, no. 1, pp. 1–12, Jan. 2021, doi: 10.1186/s42774-021-00068-9.
- [9] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA, 2016, pp. 770–778, doi: 10.1109/CVPR.2016.90.
- [10] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, "Densely Connected Convolutional Networks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Honolulu, HI, USA, 2017, pp. 4700–4708, doi: 10.1109/CVPR.2017.243.
- [11] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "ImageNet: A Large-Scale Hierarchical Image Database," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Miami, FL, USA, 2009, pp. 248–255, doi: 10.1109/CVPR.2009.5206848.
- [12] S. Ioffe and C. Szegedy, "Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift," in *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, Lille, France, 2015, pp. 448–456.
- [13] R. Geirhos, J.-H. Jacobsen, C. Michaelis, R. Zemel, W. Brendel, M. Bethge, and F. A. Wichmann, "Shortcut Learning in Deep Neural Networks," *Nature Machine Intelligence*, vol. 2, pp. 665–673, 2020, doi: 10.1038/s42256-020-00257-z.
- [14] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, "Leakage in Data Mining: Formulation, Detection, and Avoidance," *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, Art. no. 15, 2012, doi: 10.1145/2382577.2382579.
- [15] M. S. Veillette, S. Samsi, and C. J. Mattioli, "SEVIR: A Storm Event Imagery Dataset for Deep Learning Applications in Radar and Satellite Meteorology," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 22009–22019.
- [16] C. Shorten and T. M. Khoshgoftaar, "A Survey on Image Data Augmentation for Deep Learning," *Journal of Big Data*, vol. 6, Art. no. 60, 2019, doi: 10.1186/s40537-019-0197-0.

- [17] H. He and E. A. Garcia, "Learning from Imbalanced Data," IEEE Transactions on Knowledge and Data Engineering, vol. 21, no. 9, pp. 1263–1284, 2009, doi: 10.1109/TKDE.2008.239.
- [18] G. Farnebäck, "Two-Frame Motion Estimation Based on Polynomial Expansion," in Image Analysis (SCIA 2003), Lecture Notes in Computer Science, vol. 2749, Berlin: Springer, 2003, pp. 363–370, doi: 10.1007/3-540-45103-X_50.
- [19] T. Fawcett, "An Introduction to ROC Analysis," Pattern Recognition Letters, vol. 27, no. 8, pp. 861–874, 2006, doi: 10.1016/j.patrec.2005.10.010.

PROJE YÜRÜTÜCÜSÜNÜN ADI – SOYADI – İMZA	DANIŞMANIN ADI – SOYADI – İMZA
Akif KARACA 	Dr. Öğr. Üyesi Gülşah KARADUMAN 

Tarih: 25 /07/ 2026